Pasted text.txt

TXT

HW2: Multiple Linear regression
先不要直接做
分析一下以及你覺得應該怎麼做

規劃模型評估指標與視覺化呈現方式
先整理需求，再講我會怎麼做。

一、作業需求拆解

必做（基本分）

1. 資料集：來自 Kaggle，特徵數 > 13，並註明來源與連結。
2. 模型：線性回歸，可以是簡單、多元或 Auto Regression。重點放在多元線性回歸。
3. 一定要有：特徵選擇（Feature Selection）和模型評估（Model Evaluation）。
4. 預測圖要附信賴區間或預測區間。這點很容易被忽略。
5. 報告要照 CRISP-DM 六個階段寫。
6. AI 相關：
   - ChatGPT 對話匯出成 PDF
   - 用 NotebookLM 研究網路上的同題解法，寫 100 字以上摘要
   - 報告裡要明確標出「GPT 輔助內容」和「NotebookLM 摘要」
7. 繳交：GitHub repo 加網頁，形式跟 DIC2 一樣。

加分

- +1：網頁有下拉選單，可以切換「兩種 problem」
- +2：可以輸入任意 Dataset URL（例如 50_Startups.csv）並直接跑分析

二、幾個要先想清楚的地方

1. 加分項決定了網頁架構，要最先決定

+2 的要求是「輸入任意 CSV URL 就能跑回歸」。所以網頁不能只放靜態報告，必須能在使用者端或伺服器端即時計算。有三條路：

方案	優點	缺點
A. Streamlit（部署到 Streamlit Cloud）	全部用 Python，沿用 statsmodels/sklearn，做下拉選單和 URL 輸入最省事	不是 GitHub Pages，要另外部署（可以從 Pages 放連結過去）
B. GitHub Pages + 純 JS（PapaParse + 矩陣運算 + Plotly）	純靜態、速度快	要用 JS 重寫 OLS 和區間計算，跟 Python 分析可能算出不一樣的結果
C. GitHub Pages + Pyodide（瀏覽器內跑 Python）	跟 notebook 共用同一份 Python 程式碼	第一次載入要等十幾秒

我的建議：如果 DIC2 是用 GitHub Pages 交的，就選 C，一份 Python 程式碼可以同時給報告和網頁用。如果 DIC2 允許 Streamlit，選 A 最省力。這點要看你 DIC2 是怎麼交的。

2.「兩種 problem」的意思不明確

可能的解讀有三種：

- (a) 簡單線性回歸（HW1）vs. 多元線性回歸（HW2）
- (b) 兩個不同的資料集
- (c) 回歸 vs. 分類

我猜是 (a) 或 (b)。建議先問老師或同學。如果問不到，下拉選單可以設計成「HW1 簡單線性回歸 / HW2 Kaggle 多元回歸 / 自訂 URL」，三種解讀大多都能涵蓋。

3. 任意 URL 的功能要夠通用

範例的 50_Startups 只有 4 個特徵，其中 `State` 是類別欄位。所以程式要能處理：

- 自動判斷數值欄位和類別欄位，類別欄位做 one-hot（drop_first，避免完全共線）
- 讓使用者用下拉選單選 target 欄位（預設最後一欄）
- 處理缺值（先 drop 或補值）
- Kaggle 的下載連結需要登入，網頁抓不到。只有 raw.githubusercontent 這類直連 CSV 才行，網頁上要寫清楚這個限制。

4. 你之前那份資料集推薦有問題

- Predict the Flood（Playground S4E5）不太適合：
  - 它是合成資料，20 個特徵的貢獻幾乎一樣，彼此也幾乎不相關，特徵選擇做出來會沒有東西可講。
  - 資料量大約百萬筆，放進網頁或 Pyodide 會很吃力。
- Boston Housing 剛好 13 個特徵，不符合「> 13」，同學很容易踩到。
- 我比較推薦有真實共線性、缺值、類別欄位的資料，特徵選擇和診斷才有內容可寫：

資料集	約略特徵數	推薦理由
Life Expectancy (WHO)	~20	有缺值、有明顯共線性（例如 infant deaths 和 under-five deaths），VIF 分析很好發揮，約 2,900 筆
King County House Sales	~18	經典房價題，約 2 萬筆，殘差異質性明顯，適合討論取 log
Car Price (CarPrice_Assignment)	~24	類別欄位多，205 筆很輕量，適合放網頁

特徵數我是憑印象估的，選定後要實際讀 CSV 確認。我首選 **Life Expectancy**，報告最有故事可寫。

5. 多元回歸的「預測圖 + 區間」怎麼畫

多元回歸沒辦法直接畫成一條線，建議畫兩張圖：

1. 測試集預測圖：x 軸是樣本（依預測值排序），畫出實際值和預測值，再加上 95% 預測區間帶。區間用 statsmodels 的 `get_prediction().summary_frame()` 取 `obs_ci_lower/upper`。
2. 單一特徵的偏效應圖：挑最重要的一個特徵，其他特徵固定在平均值，畫回歸線，再加上 CI（平均反應）和 PI（個別預測）兩條帶。

報告裡要說明 CI 和 PI 的差別，這點很加分。

三、建議流程（CRISP-DM 對應）

1. **Business Understanding**：定義要預測什麼，以及預測結果能拿來做什麼決策。
2. **Data Understanding**：
   - 看資料的 shape、型別、缺值、描述統計
   - 畫 target 分布和相關係數熱圖
3. **Data Preparation**：
   - 處理缺值，類別欄位做 one-hot，target 視情況取 log
   - 先切 train/test（例如 80/20）
   - 所有前處理和特徵選擇都只能用 **train** 資料 **fit**，避免資料洩漏
4. **Modeling**：
   - Baseline：全特徵 OLS
   - 特徵選擇比較三種方法：
     - 用 VIF 移除共線特徵
     - RFE 或 SequentialFeatureSelector，搭配 CV 選出 k
     - Lasso（係數變成 0 的特徵就是被淘汰的）
   - 最後用 statsmodels 做 OLS，取得 p-value 和區間
5. **Evaluation**：
   - 指標：RMSE、MAE、R^2、Adjusted R^2，比較 baseline 和選特徵後的模型
   - 殘差診斷：殘差 vs. 預測值、Q-Q plot（檢查線性、常態、同質變異）
   - 加上前面說的兩張預測區間圖

6. **Deployment**：網頁（下拉選單 + URL 輸入），加上 GitHub repo。

四、Repo 結構建議

```
HW2-MLR/
├── README.md              ← 報告主體（或 docs/index.html）
├── notebook/analysis.ipynb
├── src/mlr_core.py        ← 共用的回歸函式（notebook 和網頁都用這份）
├── docs/                  ← GitHub Pages 網頁
├── data/                  ← 資料集（或只放下載說明）
└── ai_logs/               ← GPT 對話 PDF、NotebookLM 摘要
```

五、需要你自己做的部分

- **NotebookLM** 摘要：把同一個資料集的 3 ~ 5 篇 Kaggle notebook 或部落格丟進 NotebookLM，請它整理大家的做法，再寫成 100 字以上的摘要。
- 對話 **PDF**：作業指定的是 ChatGPT。如果你要用跟我的對話代替，最好先跟老師確認可不可以。

另外提醒一下：這次要交 GitHub，建議一開始就建 **repo**，每完成一個 CRISP-DM 階段就 commit 一次（例如「Data preparation done」）。這樣過程有紀錄，也可以避免改壞了救不回來。之後實作時我會提醒你每個階段該 commit 什麼。

開始之前想先確認幾件事：

1. **DIC2** 是用什麼方式交的？純 GitHub Pages、Streamlit，還是其他方式？
2. 「兩種 **problem**」老師有沒有說明？
3. 資料集要用 **Life Expectancy** 嗎？還是你有其他偏好的主題？
4. 繳交期限是什麼時候？我會依時間調整範圍，例如加分項要不要全部做。

1. 純 GitHub Pages
2. 應該事跟DIC2的下拉選單一樣
3. 好
4. 10/28

Searched the web, searched past chats, and 11 more steps ▸

No connected folder on your computer, so I'll build in the workspace and send you the files at the end. The data is in; next, a Python reference analysis to see what the results look like.

Updated tasks, ran a command ▸

Car Price is noisy in its raw form: only 205 rows, and 43 columns after one-hot. Let me check whether log(price) plus the 1-SE rule for choosing k makes it more stable.

Edited 2 files, created 3 files, and 22 more steps ▸ +4

網頁和 repo 都做好了，架構跟 DIC2 一樣，是單一 `index.html`。上方下拉選單可切換 **Problem 1 · Life Expectancy**、**Problem 2 · Car Price** 和自訂 **Dataset**，自訂 Dataset 可以貼 URL 或上傳 CSV，兩個加分項都有。

結果

Problem	最終模型	特徵數	Test R^2	95% PI 覆蓋率
Life Expectancy	RFE	20 → 8	0.828	93.3%
Car Price（log 價格）	Forward SFS	43 → 8	0.854	85.4%

作業要求的預測圖有兩張，都有畫 CI（深色帶）和 PI（淺色帶）：

- 測試集預測圖
- 單一特徵偏效應圖

網頁上的數字都和 Python statsmodels 對照過，誤差小於 1e-12。三個選項我都用 headless 瀏覽器實際跑過，沒有錯誤。

你需要自己補的三件事

1. **NotebookLM 摘要（必做）**：把同主題的 Kaggle notebook 或網路文章丟進 NotebookLM，寫 100 字以上的摘要，貼到兩個地方：
   - `index.html` 搜尋「待補」，替換那一行，並照註解把 `class="warn"` 拿掉
   - `README.md` 的「NotebookLM 摘要」
2. **AI 對話 PDF**：把這段對話匯出成 PDF，放進 `ai_logs/`。作業寫的是 ChatGPT，頁面上我已誠實標註使用的是 Claude，如果擔心可以問一下老師。
3. **README 第一行的網址**：部署完成後改成實際的 GitHub Pages 網址。

上傳步驟（跟 DIC2 一樣）

1. GitHub 新建一個 **Public** repo，例如 `AIoT-HW2-MLR`。
2. 把 zip 解壓縮，按 **Add file → Upload files**，把裡面所有檔案和資料夾一起拖進去，然後 Commit。
3. 到 **Settings → Pages**，選 `main` / `/ (root)`，按 Save。

📌 Git 提醒：

- 這次不要沿用 DIC2 的 repo，要開一個新的。如果覆蓋 DIC2 的檔案，已經交出去的 DIC2 網址會壞掉。
- 之後補 NotebookLM 摘要時，直接在 GitHub 網頁上編輯 `index.html` 再 commit，網頁會自動重新部署。

老師可能會問的點

- 為什麼用 **1-SE rule**：CV 誤差在 k 很大時幾乎是平的，1-SE rule 會挑「表現差不多但特徵最少」的模型，比較不容易過擬合。所以自訂 Dataset 跑 50_Startups 會選 k=1，DIC2 選的是 k=2，兩者不衝突，可以解釋。

- **infant deaths** 和 **under-five deaths** 係數一正一負：兩者相關係數 0.997，是共線性造成的，頁面上已經有說明。
- **Car Price** 只取 8 個特徵，**Test R^2** 比全特徵低一點：測試集只有 41 筆，波動很大。選 k 要看的是 CV 結果，不是測試集。

Hw2 mlr
ZIP

Index
Code · HTML

Download all

NotebookLM 摘要（必做）：把同主題的 Kaggle notebook 或網路文章丟進 NotebookLM...

這部分可以詳細解釋需要做甚麼嗎?

整理数据集案例与学习资源建议。
作業規定要用 NotebookLM 研究「網路上同主題的解法」，寫成 100 字以上的摘要放進報告，並標示「NotebookLM 摘要」。網頁上已經留好標示和位置，只差內容。我沒辦法替你操作 NotebookLM，下面是完整步驟。

步驟 1：建立筆記本

1. 打開 https://notebooklm.google.com，用 Google 帳號登入。
2. 按「新建筆記本」，名稱可以取「HW2 Life Expectancy 回歸」。

步驟 2：加入 4～6 個來源

NotebookLM 只會根據你給的來源回答，所以來源要是別人對同一個資料集做的回歸分析。以主要題目 Life Expectancy 為例，可以用這些：

- Vipul97/life-expectancy-prediction：我們網頁內嵌的資料就是從這裡取的
- Akshu577/life-expectancy-analysis：回歸加特徵選擇
- RheaDsouza/Life-Expectancy-Prediction_World-Health-Organization：比較多種回歸模型
- KAR-NG/Life-Expectancy-Statistical-Analysis-WHO-：統計分析
- Kaggle 資料集的 Code 分頁：https://www.kaggle.com/datasets/kumarajarshi/life-expectancy-who/code，挑 1～2 篇票數高的 notebook

加來源的方法：

- 按「新增來源」，選「網站」，貼上網址。
- GitHub 網址如果讀不到內容，改貼 repo 裡的 README，或 `.ipynb` 檔案頁面的網址。
- Kaggle notebook 有時需要登入，NotebookLM 會讀不到。這時可以在 Kaggle 頁面全選複製文字，用「複製的文字」來源貼上；或用瀏覽器「列印 → 存成 PDF」後上傳 PDF。

步驟 3：請 NotebookLM 整理

在右側對話框貼這段提示：

```
請比較這些來源如何用回歸分析預測 WHO Life Expectancy 資料集，整理：
1. 缺值怎麼處理（刪除或補值）
2. 用了哪些特徵選擇方法、最後保留哪些重要特徵
3. 用了哪些模型，評估指標與結果（R²、RMSE）
4. 共同的發現（例如 HIV/AIDS、Schooling、Adult Mortality 的影響）以及常見的問題（例如共線性）
請用繁體中文，約 200 字。
```

步驟 4：改寫成你的摘要

NotebookLM 的回答不要整段照貼，建議稍微整理成自己的話，最後再加一兩句和你的作法比較，例如：

> 與上述作法相比，本作業以 5-fold CV 搭配 1-SE rule 選擇特徵數，最後保留 8 個特徵，測試集 R^2 為 0.828，與多數來源的線性回歸結果相近；同時也觀察到 infant deaths 與 under-five deaths 高度共線的問題。

這樣整段會超過 100 字，也看得出你有讀懂。建議把 NotebookLM 的畫面截圖，連同對話 PDF 一起放進 `ai_logs/`，當作使用證明。

Car Price 是第二題，不一定要另外做。想做的話，用同樣方法另開一本筆記本，來源用 https://www.kaggle.com/datasets/hellbuoy/car-price-prediction/code 。

步驟 5：貼到兩個地方

可以直接在 GitHub 網頁上改：點檔案 → 右上角鉛筆圖示 → 修改 → Commit changes。

① `index.html`：按 Ctrl+F 搜尋「待補」，會找到這兩行：

```html
<!-- 🖍️ 把 NotebookLM 摘要（100 字以上）貼在下面這個 <p> 裡，並把 class="warn" 拿
<p class="warn">（待補：請貼上 NotebookLM 對網路上同主題解法的研究摘要，100 字以上）
```

把第二行換成你的摘要（註解那行可以刪掉）：

```html
<p>NotebookLM 整理了 5 個以 WHO Life Expectancy 資料做回歸分析的專案……（你的摘要）
```

`class="warn"` 要拿掉，否則摘要會顯示成橘色的警告框。

② `README.md`：找到這一行：

```
> （待補：NotebookLM 對網路上同主題解法的研究摘要，100 字以上）
```

換成 `> 你的摘要`。摘要如果有好幾段，每段開頭都要加 `>`。

Commit 後等 1～2 分鐘，重新整理 GitHub Pages 網址，確認「AI 協助說明」區的 NotebookLM 摘要已經出現，而且不是橘色框。

如果 HTML 怕改錯，可以把 NotebookLM 的回答直接貼給我，我幫你整理成摘要，並改好 `index.html` 和 `README.md` 給你重新上傳。